刘宸旭 Chenxu Liu

物理学学士 — 山东大学（青岛）

202422201069@mail.sdu.edu.cn · physicsliu299792458@outlook.com · github.com/PhyLiusir
中国 青岛
中文（母语）· 英文（工作语言）

教育经历 EDUCATION

山东大学（青岛） 2024 – 2028

前沿交叉科学青岛研究院 · 2024 级，预计 2028 年毕业

物理打底——统计物理、量子场论、数值方法当工具；工作时间花在大模型与智能体上：读、在小规模上复现，然后只改一处，看它在哪儿坏。

独立工作 —— 大模型与智能体 2024 – 至今

服务与后训练管线在小规模上复现；智能体工具接口按真实任务批重写；每个结果连同脚本留成日志。

工作方式

从第一性原理推，不从惯例抄 —— 宁可丑，不可假；每个结论都要能对着日志重放一遍。

研究兴趣 RESEARCH INTERESTS

大模型： 部署与服务的经济学、后训练（SFT → 偏好 → RL），以及新的注意力架构——Loop Attention。

智能体： 智能体构建、工具设计、多智能体协作、检索增强生成。

研究方向与进行中的工作 RESEARCH DIRECTIONS

- **部署（LM 01）。** 同一个模型在不同服务框架、批处理策略与精度下的成本结构——每 token 成本、P99 延迟与显存峰值，三个数必须一起看。
- **后训练（LM 02）。** 在小规模上把一条完整的 SFT → 偏好 → RL 链复现一遍，再逐级做消融；重点是哪些增益在小一号的模型上还能活下来。
- **Loop Attention（LM 03）。** 把同一个注意力块跨深度复用——显存、墙钟时间与训练稳定性，和堆叠基线比。主线。
- **智能体构建（AG 01）。** 循环、记忆与规划的最小可用组合；以「无工具智能体的失败类型学」作为起点。
- **工具设计（AG 02）。** 给一批真实任务重做 schema、错误面与返回结构，比较改动前后的失败分布。
- **多智能体协作（AG 03）。** 先要一个足够强的单智能体基线；多智能体必须在它上面稳定取胜，才谈拆角色。
- **RAG（AG 04）。** 一套带引用要求的问答集与打分脚本：答案必须落到具体段落，否则判负。

在做的

- **LM 03 · Loop Attention — 深度复用的账。** 显存、时延与训练稳定性，和堆叠基线比。
- **LM 01 · 服务对照记录。** 同一个模型在多种服务与量化配置下的吞吐、显存与尾延迟。
- **AG 02 · 工具接口。** 给一批真实任务重做 schema 与错误处理，记录失败方式的变化。
- **AG 04 · 带引用要求的 RAG 评测集。** 答案必须落到具体段落，否则判负。

开放问题

- **LM 01 · 部署.** 批处理与尾延迟的交换曲线，在什么负载下会反号？ · 量化省下的那点精度，换来的吞吐到底值不值？ · KV cache 的显存预算，应该按请求算还是按租户算？
- **LM 02 · 后训练.** 数据筛选用什么指标，才能预测下游的真实增益？ · 评测集被污染，有哪些可观测的信号？ · RL 阶段的收益，从多大的模型开始才出现？
- **LM 03 · 新注意力架构 · Loop Attention.** 深度复用与宽度扩展的交换点在哪里？ · 复用带来的表示坍缩，用什么指标能提前发现？ · 在长上下文任务上，复用会不会反而变成优势？
- **AG 01 · Agent 搭建.** 失败模式里，哪些靠加工具能救，哪些不能？ · 记忆写入的时机，应该由谁来决定？ · 规划在什么任务长度上才开始回本？
- **AG 02 · 工具设计.** 错误信息写多细，模型才会真的改行为？ · 工具粒度粗一点好，还是细一点好？ · 返回值该结构化到什么程度？
- **AG 03 · 多 Agent 协作.** 协调开销随角色数怎么增长？ · 什么信号说明应该合并角色，而不是继续拆？ · 失败是如何在角色之间传播的？
- **AG 04 · RAG.** 切分粒度与检索召回的关系，在什么区间最稳？ · 引用错误的代价，应该比不引用更高吗？ · 重排在多大库规模上才回本？

技术能力 TECHNICAL SKILLS

语言	Python（主力）、C++ 与 CUDA、Bash、Git 与代码评审
大模型侧	PyTorch 训练与微调、transformers 与自定义层、推理服务与量化、LoRA 与偏好对齐
智能体侧	工具与函数调用、多智能体编排、向量检索与 RAG、评测集与打分脚本
工具与环境	Linux 与容器、分布式训练基础、可复现实验、技术写作